

② 텍스트 데이터를 어떻게 집합을 이용하여 표현할까요?

텍스트 데이터의 집합 표현

컴퓨터는 문장과 단어 등으로 이루어진 텍스트 데이터를 사람처럼 글자 형태로 인식할 수 없다. 컴퓨터가 데이터를 인식할 수 있게 하기 위해서는 데이터를 수와 수학 기호를 이용하여 표현하여야 한다.

먼저 텍스트 데이터를 집합을 이용하여 표현하는 방법을 알아보자.

다음은 한 음식점을 방문한 사람들의 댓글이다.



텍스트 데이터를 집합으로 표현하기 위해서는 먼저 아래와 같이 띄어쓰기를 기준으로 각 문장을 단어별로 분리한다.

댓글 A	분위기도	신선한	재료도	좋다.
댓글 B	맛은	보통이고	분위기는	최고예요.
댓글 C	멋있는	분위기!	최고의	재료!



문장에서 의미를 분석하는 데 불필요한 단어를 '불용어'라고 하고, 주로 조사, 접미사, 접속사, 구두점 등을 의미한다.

분리된 단어에서 의미를 분석하는 데 불필요한 부분, 즉 불용어를 제거한다. 예를 들어 '분위기도', '분위기는'과 같은 단어들은 조사를 제거하고 남은 단어 '분위기'로 바꾼다.

댓글 A	분위기	신선하다	재료	좋다
------	-----	------	----	----

댓글 B	맛	보통	분위기	최고
------	---	----	-----	----

댓글 C	멋있다	분위기	최고	재료
------	-----	-----	----	----



불용어(Stopwords)

각 댓글에서 불용어를 제거하고 남은 단어를 원소로 하는 집합을 차례대로 집합 A , B , C 라 하면

$$A = \{\text{분위기, 신선하다, 재료, 좋다}\},$$

$$B = \{\text{맛, 보통, 분위기, 최고}\},$$

$$C = \{\text{멋있다, 분위기, 최고, 재료}\}$$

이다.

이때 세 집합 A , B , C 를 각각 댓글 A , B , C 의 **단어집합**이라고 한다.

또한, 세 집합 A , B , C 의 합집합 $A \cup B \cup C$ 를 집합 X 라고 하면

$$X = \{\text{분위기, 신선하다, 재료, 좋다, 맛, 보통, 최고, 멋있다}\}$$

이다.

이때 집합 X 는 세 댓글 전체로 구성된 단어집합이다.

이러한 과정을 통해 만든 단어집합은 음식점의 분위기나 맛 등을 파악하는 데 도움을 준다. 즉, 텍스트 데이터를 집합을 이용하여 표현하는 것은 텍스트 데이터의 의미를 분석할 수 있는 발판을 마련해 준다.

확인하기 3

인공지능과 관련한 인터넷 기사에 실린 문장에서 단어집합을 만들어 보시오.

- 현대는 사람과 인공지능이 협업하는 시대이다.
- 인공지능 기술 발전은 사람을 향해야 한다.